MCMC convergencia

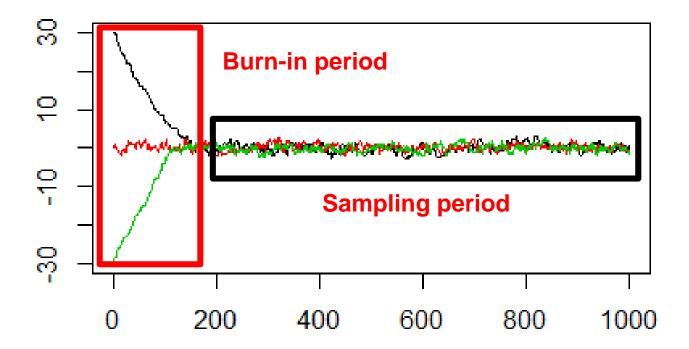
Modelos Bayesianos con aplicaciones ecológicas Dr. Cole Monnahan University of Concepción, Chile Enero, 2019

Convergencia de MCMC

- MCMC muestras converge como n va a infinito
- Pero solo tenemos una cantidad finita (e.g., 5000).
- Significa que hay que ser cuidadoso que la cadena genera muestras de la posterior
- Es decir, que la cadena (probablemente) ha convergido.

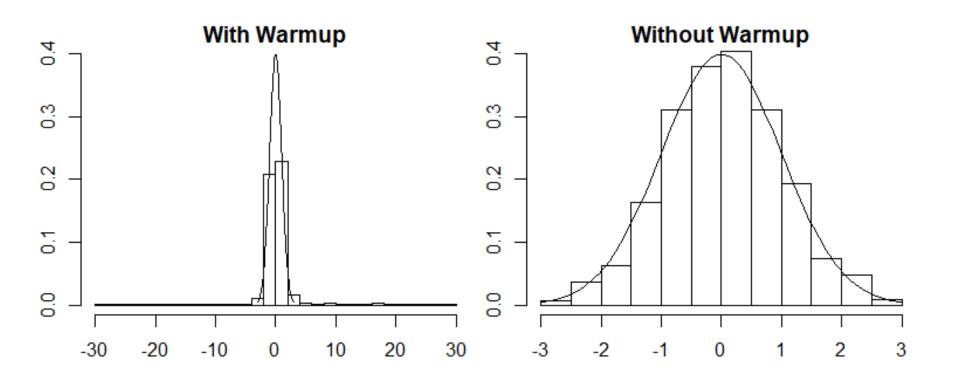
Periodo burn-in o warmup

Qué pasa si usamos inicializaciones muy amplias?



Periodo burn-in o warmup

Podemos usar las muestras del periodo 'burn-in'?



Periodo burn-in o warmup

- MCMC convergencia es cuando las cadenas son indistinguible
- Tenemos que quitar las muestras antes de convergencia, porque no son de la distribución a posteriori.
- Cómo conocimos si las cadenas no han convergido?
- Chequeamos con estadísticas como "Rhat" y otras (más tarde)

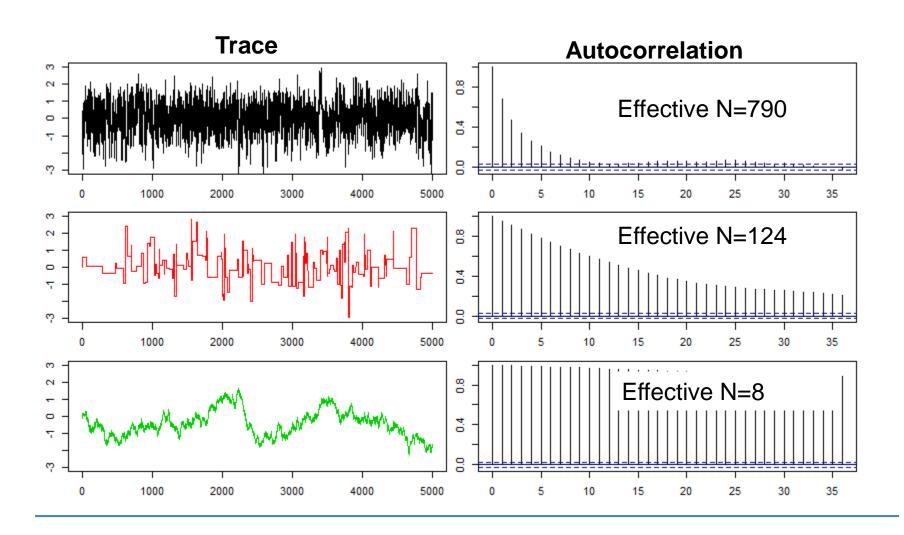
La calibración (tuning)

Tuvimos el variable "U" en el algoritmo:

```
new <- x[i-1]+runif(1,-U,U)
```

- Cuál es el efecto con diferente valores?
- [Mostrar en R]
- Durante el periodo burn-in, el algoritmo se afina
- Por eso debemos usar un periodo suficientemente largo para afinar

La afinación (tuning)



Thinning

- Muestras efectivas (n_eff/ESS o effective samples) son menos que N, y se disminuye como autocorrelación se aumenta.
- Si una cadena tiene mucha autocorrelación, tenemos que generar muchas muestras para tener suficiente muestras efectivas.
- En algunos casos, quitamos algunas muestras para no tener demasiado
- Pero perdimos información siempre cuando hacemos "thinning"

Diagnostic checks w/ CODA

- Si usas muestras sin convergencia, vas a obtener la respuesta incorrecta!
- Es tu responsabilidad asegurar que no hay evidencia que las cadenas no han convergido.
- En este curso usaremos: Rhat y ESS
- Se recomienda usar inicializaciones muy amplias

Geweke (1992)

• Geweke (1992) statistic – t test equivalent to assess the means of first (T_A) and last (T_B) parts of the Markov chain

$$\delta_A = \frac{1}{T_A} \sum_{t=1}^{T_A} h(x^{(t)}), \qquad \delta_B = \frac{1}{T_B} \sum_{t=T-T_B+1}^{T} h(x^{(t)})$$

$$\sqrt{T}(\delta_A - \delta_B) / \sqrt{\frac{\sigma_A^2}{\tau_A} + \frac{\sigma_B^2}{\tau_B}}$$
, $\tau_i = T_i / T$, $\tau_i + \tau_i < 1$

- Useful for a single chain or multiple chains
- Test statistic is standard Z score

Gelman-Rubin

Gelman and Rubin (1992) statistic (multiple chains): comparison of between-chain and within-chain variance, probably most commonly used diagnostic. Let $\xi_m^{(t)}$ be a sample from chain m in iteration t

$$B_T = \frac{1}{M-1} \sum_{m=1}^{M} (\overline{\xi}_m - \overline{\xi})^2$$
, where $\overline{\xi}_m = \frac{1}{T} \sum_{t=1}^{T} \xi_m^{(t)}$, $\overline{\xi} = \frac{1}{M} \sum_{m=1}^{M} \overline{\xi}_m$

$$W_T = \frac{1}{M-1} \sum_{m=1}^{M} s_m^2 = \frac{1}{M-1} \sum_{m=1}^{M} \frac{1}{T-1} \sum_{t=1}^{T} (\xi_m^{(t)} - \overline{\xi}_m)^2$$

$$R_T^2 = \frac{\hat{\sigma}_T^2 + \frac{B_T}{M}}{W_T} \frac{\nu_T + 1}{\nu_T + 3} \qquad \text{where} \quad \hat{\sigma}_T^2 = \frac{T - 1}{T} W_T + B_T$$
 and
$$\nu_T = 2(\hat{\sigma}_T^2 + \frac{B_T}{M})^2 / W_T \quad \text{is the estimated df}$$

The "shrink factor" R - converges to 1 under stationarity, so large values indicate lack of convergence, quantiles calculated via t distribution

Effective sample size

- An MCMC chain has T iterations, but not T independent samples from the chain, thus we want a metric for helping determine the number of independent samples.
- Compute effective sample size as

$$\tau_T = T/\kappa(h)$$

$$\kappa(h) = 1 + 2 \sum_{t=1}^{\infty} \operatorname{corr}\left(h(x^{(0)}), h(x^{(t)})\right)$$

Use of coda package in R

coda implements many diagnostics:

- Cumulative distribution plot cumuplot ()
- Cramer-von Mises heidel.diag()
- 3. Geweke geweke.diag()
- 4. **Gelman-Rubin** gelman.diag(), and gelman.plot()
- Effective sample size effectiveSize()

Una introducción del software JAGS

Modelos Bayesianos con aplicaciones ecológicas Dr. Cole Monnahan University of Concepción, Chile Enero, 2018

Software implementing MCMC JAGS – Just Another Gibbs Sampler

- Sampler
 - Gibbs for conjugate priors
 - Adaptive-Rejection Metropolis for non-conjugate
- Conditional updating (one parameter at a time)
- Runs multiple chains at a time
- Diagnostics via coda R package

JAGS syntax- a regression example

Model

$$Y_i \sim N(\mu_i, \tau)$$
$$\mu_i = \alpha + \beta x_i$$

Priors

$$\alpha \sim N(0.1 \times 10^{-6})$$
 $\beta \sim N(0.1 \times 10^{-6})$
 $\tau \sim \Gamma(0.001, 0.001)$

JAGS/BUGS code

```
#regression model
    for(i in 1 : N) {
        Y[i]~dnorm(mu[i], tau)
        mu[i]<- alpha+beta*x[i]
      }

#PRIORS
    alpha~ dnorm(0,1.0E-6)
    beta~dnorm(0,1.0E-6)
    tau~dgamma(0.001,0.001)
    sigma<-1/sqrt(tau)</pre>
```

JAG syntax- a GLM example

Model

```
Y_i \sim Poisson(\lambda)
```

Priors

```
\lambda \sim Gamma(1,1)
```

[Demo in R]

JAGS code (save to insect1.jags)

```
model {
    ## prior
    lambda~dgamma(1,1)
    ## likelihood
    for(i in 1:N) {
        Y[i]~dpois(lambda)
    }
}
```

BUGS syntax- a GLM example

R code

```
library (R2jags)
dat <- dget('datos/insect data2.txt')</pre>
plot(dat$x, dat$Y, xlab = "Female Egg Compliment",
     vlab = "Eggs laid on host", pch = 15)
inits <- function() list(lambda=runif(1,1,15))
fit1 <- jags(data=dat, inits=inits, parameters.to.save='lambda',
      model.file='modelos/insect1.jags', n.chains=3, n.iter=2000,
      n.burnin=500, n.thin=1)
traceplot(fit1)
effectiveSize(fit1)
gelman.diag(as.mcmc(fit1))
post <- data.frame(fit1$BUGSoutput$sims.matrix)</pre>
hist(post$lambda)
```

Homework

- Copy the code from the previous slides and rerun the model. Copy the JAGS code into a separate file (insect1.jags).
- 2. Fit the normal conjugate example from lecture using JAGS and compare to exercise from R.

```
y <- .5 # observed
sigma <- 1 # assume known
mu0 <- -2 # prior mean
tau0 <- .5 # prior SD</pre>
```

[Note: JAGS uses dnorm(mu,tau) parameterization where tau^2=1/sigma^2.

References

- Gelman, A., J. B. Carlin, H. S. Stern, and D. B. Rubin. 2014. Bayesian data analysis. Taylor & Francis.
- Plummer, M., N. Best, K. Cowles, and K. Vines. 2006.
 CODA: Convergence Diagnostics and Out Analysis for MCMC. R News 6:7-11.
- Link, W. A. and M. J. Eaton. 2012. On thinning of chains in MCMC. Methods in Ecology and Evolution 3:112-115.
- Geweke, J. (1992). Evaluating the accuracy of sampling-based approaches to the calculation of posterior moments (with discussion). In Bernardo, J., Berger, J., Dawid, A., and Smith, A., editors, Bayesian Statistics 4, pages 169–193. Oxford University Press, Oxford.
- Gelman, A. and Rubin, D. (1992). Inference from iterative simulation using multiple sequences (with discussion). Statistical Science, 7:457–511.