
Una revisión del curso y inferencia Bayesiana

Modelos Bayesianos con aplicaciones ecológicas

Dr. Cole Monnahan

University of Concepción, Chile

Enero, 2019

Conceptos importantes

- La inferencia Bayesiana es un paradigma diferente que la frecuentista
- Las probabilidades son grados de creencia
- Se actualiza la creencia *a priori* con los datos
- La incertidumbre se cuantifica mediante probabilidades
- **Calculo de las probabilidades se requiere integración**

📌 Pinned Tweet



\mathfrak{Michael Betancourt} @betanalpha · 5 Jan 2017

Remember that using Bayes' Theorem doesn't make you a Bayesian. Quantifying uncertainty with probability makes you a Bayesian.

Componentes de la regla de Bayes

- $P(\theta)$ = “Prior”: *la incertidumbre antes de experimento o conocimiento de un experto*
- $P(y|\theta)$ = “Likelihood”: *la verosimilitud de los datos dado los parámetros – lo mismo como clásica*
- $P(y)$ = *Una constante que no se puede calcular*
- $P(\theta|y)$ = “Posterior”: *la creencia que resulta de la combinación de dos fuentes da información: prior y datos.*
 - ❑ Es una distribución de probabilidad
 - ❑ La usamos para hacer inferencia

Resumen de las diferencias de los paradigmas de inferencia.

	Frequentist	Bayesiana
Que es estimado?	$P(Y H)$ Datos dado el hipótesis	$P(H Y)$ Hipótesis dado los datos
La definición de probabilidad	frecuencias (infinitas) relativas de eventos	Grado de creencia
Fuentes de la información	Solo los datos	Los datos y información a priori
La definición de los parámetros	Estimaciones de cantidades “verdaderas”	Variables aleatorias estadísticas
Método de inferencia	Máximo verosimilitud	Integración (de posteriori)

Las ventajas de inferencia Bayesiana

- Hay respuestas intuitivas: los parámetros son distribuciones de probabilidad.
- Poder formalmente incorporar conocimiento antes del experimento
- Las suposiciones asintóticas no son necesarios
- La estimación de los modelos jerárquicos es natural y fácil
- Análisis de decisión: Poder calcular probabilidades de las consecuencias de varias acciones. (Punt and Hilborn 1997)

Desventajas

- Toma mas tiempo para estimar
- En general, la especificación de los priors
 - Poder ser sensitivo para la transformación de los parámetros. (e.g., Thorson and Cope 2017, Maunder 2003)
 - Poder ser difícil determinar apropiados “priors”
 - P.ej., no hay “uninformative priors”
- Es sensible a las transformaciones de los parámetros (Punt and Hilborn (1997)).

Construyendo modelos Bayesianos

- Gelman et al (2014) recomienda tres pasos básicos:
 1. Hacer un modelo colectivo por todos los cantidades (datos y parámetros) del problema
 2. Condicionar el modelo a los datos observados y estimar la probabilidad *a posteriori*
 3. Evaluar el ajuste, realizar si necesario, y después hacer inferencia (calcular probabilidades).

Modelos jerárquicos

- MJ requiere integración para hacer inferencia
- Es difícil con máximo verosimilitud
- Pero natural con métodos Bayesianos
- Porque MCMC ya está integrando!
- MJ son herramientas muy poderosa y eran difícil de ajustar...
- Hasta software como Stan/JAGS que son flexibles para construir modelos arbitrarios

Consejo I

- Les recomiendo usar R para simular datos que son similares que los reales
- Después, los ajusta con JAGS/Stan para saber si el software funciona como piensas
- Usa *prior predictive distribution* para entender el efecto de las priors en el modelo
- Usa *posterior predictive distribution* para chequear que el modelo es bueno

Consejo II

- Usa algunas versiones de la prior, y plotea las priors vs posterior
- Comienza con JAGS y usa Stan cuando el análisis es demasiado lento
- Es tu responsabilidad asegurar convergencia. Usa Rhat y ESS.
- Un análisis Bayesiano toma mucho tiempo
- Comienza con un modelo simple y agrega complejidad lentamente

Referencias: Inferencia Bayesiana

- Gelman et al (2014)
- Korner-Nievergelt et al. (2015)
- Hooten and Hobbs (2015)
- Punt and Hilborn (1997)

Referencias: Modelos jerarquicos

- Royle and Dorazio (2008)
- Thorson and Minto (2015)
- Gelman et al. (2006)

Stan

- <https://betanalpha.github.io/writing/>
- rstanarm (<https://cran.r-project.org/web/packages/rstanarm/vignettes/rstanarm.html>)
- <https://mc-stan.org/users/documentation/>
- <https://mc-stan.org/users/documentation/tutorials.html>
- Stan functionality in TMB and ADMB; Monnahan and Kristensen (2018)

References

- Hooten, M. B. and N. T. Hobbs (2015). "A guide to Bayesian model selection for ecologists." Ecological Monographs **85(1)**: 3-28.
- Gelman, A., J. B. Carlin, et al. (2014). Bayesian data analysis, Taylor & Francis.
- Punt, A. E. and R. Hilborn (1997). "Fisheries stock assessment and decision analysis: The Bayesian approach." Reviews in Fish Biology and Fisheries **7(1)**: 35-63.
- Korner-Nievergelt, F., T. Roth, et al. (2015). Bayesian data analysis in ecology using linear models with R, BUGS, and Stan: including comparisons to frequentist statistics, Academic Press.
- Thorson, J. T. and C. Minto (2015). "Mixed effects: a unifying framework for statistical modelling in fisheries biology." ICES Journal of Marine Science **72(5)**: 1245-1256.
- Royle, J. A. and R. M. Dorazio (2008). Hierarchical modeling and inference in ecology: The analysis of data from populations, metapopulations and communities, Academic Press.
- Gelman, Andrew, and Jennifer Hill. *Data analysis using regression and multilevel/hierarchical models*. Cambridge university press, 2006.
- Monnahan, C. C. and K. Kristensen (2018). "No-U-turn sampling for fast Bayesian inference in ADMB and TMB: Introducing the adnuts and tmbstan R packages." Plos One **13(5)**: e0197954.